



TALLER PRÁCTICO

Proyecto Final ML1: Sistema de Inteligencia Multifuente


Enunciado oficial · Machine Learning 1 · Ciencia de Datos

Julián Zuluaga — Docente

14 de abril de 2026

Enunciado del Proyecto Final

Machine Learning 1 (*ML1-2026I*)
Pregrado en Ciencia de Datos
Universidad Externado de Colombia



El proyecto parte de un contexto real de escalada regional. La pregunta no es solo qué datos existen, sino cómo convertirlos en evidencia analítica útil.

Propósito

El proyecto final de *Machine Learning 1* busca que cada grupo construya un **sistema de inteligencia multifuente** alrededor de la escalada del conflicto *Irán-Israel-EE.UU.*, usando exclusivamente **fuentes gratuitas y públicas**.

La meta no es replicar una plataforma militar o un producto tipo Palantir. La meta es demostrar criterio de ciencia de datos en cuatro dimensiones:

1. conseguir y documentar datos reales;
2. construir un dataset integrado y utilizable;
3. formular y resolver una pregunta propia de machine learning;
4. comunicar resultados en un dashboard web desplegado.

El reto

Cada grupo de 3 estudiantes deberá proponer, desarrollar y presentar un proyecto que combine:

- adquisición de datos por API o web scraping responsable;
- análisis exploratorio;
- una tarea principal de machine learning alineada con el curso;
- un dashboard web desplegado;
- una reflexión crítica sobre límites, sesgos y calidad de datos.

El proyecto debe ser **propositivo**. Eso significa que el grupo debe tomar decisiones reales:

- qué fuentes usar;
- cuál será la unidad de análisis;
- qué variable objetivo o tarea de ML tendrá sentido;
- qué modelos comparar;
- cómo traducir el análisis a una interfaz útil.

Pregunta orientadora del curso

¿Hasta qué punto un conjunto de fuentes abiertas y gratuitas permite detectar, clasificar o modelar episodios de escalada regional en el conflicto Irán-Israel-EE. UU.?

Cada grupo puede reformular esta pregunta para convertirla en una versión más concreta y analíticamente defendible.

Entregable central

El entregable final es un **sistema de inteligencia multifuente** que incluya:

- un dataset propio construido por el grupo;
- una tarea principal de machine learning;
- mínimo 3 modelos comparados;
- un dashboard web desplegado;
- documentación clara del proceso.

Alcance mínimo obligatorio

Cada grupo debe:

- trabajar con entre 3 y 5 fuentes;
- incluir al menos:
 - 1 fuente textual;
 - 1 fuente estructurada u operativa;
 - 1 fuente adicional de contexto, movilidad o señal social;
- formular una pregunta propia;
- definir una unidad de análisis;
- entrenar mínimo 3 modelos;
- comparar resultados con métricas adecuadas;
- desplegar un dashboard accesible por URL.

Lo que sí y lo que no es este proyecto

Sí es


- un proyecto de ciencia de datos aplicada;
- un problema de ML formulado con datos reales;
- una integración entre datos, método y comunicación;
- una oportunidad para tomar decisiones propias.

No es

- un collage de visualizaciones sin pregunta analítica;
- un simple scraping sin modelado;
- una copia de un dashboard existente;
- una plataforma “militar” o “forense” de tiempo real;
- una entrega donde el dashboard sea más importante que el modelo.

Fuentes sugeridas

Las siguientes fuentes son una referencia de partida. No son la única opción, pero sí representan un conjunto realista y gratuito para trabajar en el curso.



Un proyecto fuerte no necesita decenas de APIs. Necesita combinar bien eventos, noticias, movilidad, social y contexto.

Eventos y conflicto estructurado

- ACLED
- UKMT0 o fuentes similares de incidentes marítimos

Noticias y medios

- GDELT
- BBC RSS
- AL Jazeera RSS
- Google News RSS

Movilidad

- OpenSky
- AISStream o fuentes equivalentes gratuitas si el grupo logra integrarlas

Contexto y señales complementarias

- NASA FIRMS
- Cloudflare Radar si el grupo logra autenticarse y consumirla correctamente
- otras fuentes abiertas justificadas por el equipo

Social / conversación digital

- Bluesky
- YouTube metadata o comentarios

Importante: si un grupo quiere usar una fuente adicional, puede hacerlo, siempre que sea gratuita, pública y documentada en la entrega.

Tabla de fuentes sugeridas

La siguiente tabla resume mejor qué aporta cada fuente y cómo podría entrar al proyecto.

Fuente	Tipo de acceso	Tipo de datos	Qué puede aportar al proyecto
ACLED	API / registro	eventos estructurados de conflicto	actores, tipo de evento, fecha, lugar, severidad aproximada
UKMTO	web / scraping	incidentes marítimos y alertas	riesgo marítimo, seguridad en Hormuz, contexto operacional
GDELT	API	noticias, tono, menciones geográficas	narrativa mediática, intensidad informativa, NLP
BBC RSS	RSS	titulares y enlaces	seguimiento editorial y corpus noticioso
Al Jazeera RSS	RSS	titulares y enlaces	cobertura regional y contraste editorial
Google News RSS	RSS	agregación de noticias	diversidad de medios y monitoreo temático
OpenSky	API	estados y trayectorias de vuelos	movilidad aérea, densidad, patrones por ventana temporal
AISStream		tráfico AIS de buques	

Fuente	Tipo de acceso	Tipo de datos	Qué puede aportar al proyecto
	WebSocket API		movilidad marítima, actividad en rutas críticas
NASA FIRMS	API	hotspots e incendios satelitales	contexto geoespacial, señales térmicas, actividad anómala
Cloudflare Radar	API	conectividad y anomalías de internet	contexto digital, caídas, actividad de red
Bluesky	API	posts y conversación pública	capa social, texto corto, señales discursivas
YouTube	API / metadata	videos, títulos, descripciones, comentarios	conversación audiovisual, contexto explicativo, comentarios

Cómo pensar estas fuentes

- **Eventos** : ayudan a construir labels o targets.
- **Noticias** : ayudan a construir corpus textual, narrativa y embeddings.
- **Movilidad** : ayudan a capturar comportamiento operativo por tiempo y región.
- **Social** : ayudan a observar discurso público o conversación digital.
- **Contexto** : ayudan a enriquecer explicaciones o crear features adicionales.

Sugerencias para conseguir datos

FLUJO DEL PROCESO DE DATOS



El proyecto no se evalúa por descargar APIs, sino por transformar fuentes heterogéneas en un pipeline claro y reproducible.

1. No empiecen por el dashboard

Empiecen por definir:

- qué quieren explicar o predecir;
- qué unidad de análisis van a usar;
- qué datos podrían respaldar esa pregunta.

2. Bajen primero una muestra pequeña

Antes de “montar todo”, prueben:

- si la fuente responde;
- qué campos trae;
- qué tan limpia está;
- qué tanto ruido tiene;
- si realmente sirve para su pregunta.

3. Normalicen desde el principio

Intenten que toda fuente termine, al menos, con campos comparables como:

- `timestamp`

- `source`
- `country`
- `lat`
- `lon`
- `text`
- `event_type`
- `value` o `score`

4. Documenten sus decisiones

Cada grupo debe poder responder:

- por qué eligió esas fuentes;
- qué dejó por fuera;
- qué limpió;
- qué supuestos hizo;
- qué limitaciones encontró.

5. No persigan “tiempo real” perfecto

No es necesario tener streaming completo o una infraestructura profesional. Es preferible:

- un pipeline pequeño pero reproducible,

que

- una promesa ambiciosa que no se puede sostener técnicamente.

Unidad de análisis: decisión crítica

El grupo debe escoger y justificar su unidad de análisis.

Opciones razonables:

- `documento` : noticia, post o comentario;
- `evento` : incidente, alerta o registro individual;
- `ventana temporal` : país-día, región-6h, región-12h.

La unidad de análisis condiciona:

- el target;
- los features;

- los modelos;
- las métricas;
- el diseño del dashboard.

Problemas de ML posibles

El grupo debe definir una tarea principal de machine learning. Estas son referencias posibles, no una lista cerrada.

1. Clasificación supervisada

Ejemplos:

- clasificar noticias o posts por tipo de narrativa;
- clasificar ventanas temporales por nivel de escalada;
- clasificar regiones o periodos por riesgo operativo.

2. Regresión

Ejemplos:

- estimar intensidad mediática;
- predecir número de eventos en la siguiente ventana;
- construir un score continuo de riesgo.

3. Clustering como apoyo

Ejemplos:

- agrupar narrativas;
- identificar perfiles de días o regiones;
- explorar similitud semántica en noticias o posts.

Nota: el clustering no reemplaza la tarea principal. Puede ser una capa exploratoria adicional.

Alineación con los temas reales del curso

De acuerdo con la estructura actual de [ML1-2026I](#) registrada en Academy, los temas del curso incluyen:

- fundamentos del aprendizaje supervisado

- KNN
- Naive Bayes
- K-Means
- métricas de evaluación
- balanceo de clases
- validación
- feature engineering y pipelines
- regresión lineal
- clasificación lineal
- regularización
- despliegue
- diagnóstico y ética

Esto significa que el proyecto final debe estar **anclado primero a los modelos y conceptos vistos en clase**.

Modelos compatibles con el curso

Dependiendo del problema planteado, pueden considerarse:

- KNN
- Naive Bayes
- K-Means
- Linear Regression
- Logistic Regression
- modelos lineales con regularización como Ridge y Lasso

Modelos adicionales permitidos

Si un grupo quiere usar modelos adicionales, puede hacerlo, siempre que:

- mantenga una línea base basada en modelos del curso;
- justifique por qué el modelo adicional aporta valor;
- siga siendo capaz de explicar con claridad el procedimiento y la evaluación.

Ejemplos de modelos adicionales aceptables:

- Decision Tree
- Random Forest

- Gradient Boosting

La regla no es “usar lo más complejo posible”, sino demostrar criterio y comparación.

Sobre embeddings

Se permite el uso de embeddings para representar texto, agrupar documentos o enriquecer features, siempre que:

- tengan una justificación clara;
- se comparen con una línea base simple;
- no sustituyan la explicación del problema.

Ejemplos válidos:

- TF-IDF + Logistic Regression VS Embeddings + Logistic Regression
- TF-IDF + Naive Bayes VS Embeddings + KNN

Qué debe mostrar el dashboard



El dashboard debe ser ambicioso y atractivo, pero siempre conectado con fuentes, métricas, modelos y hallazgos reales.

El dashboard final debe incluir, como mínimo:

- una explicación breve del problema del grupo;
- las fuentes usadas;

- visualizaciones exploratorias;
- filtros por fecha, región, categoría o fuente;
- resultados del modelo;
- métricas principales;
- interpretación de hallazgos;
- limitaciones del sistema.

El dashboard debe estar **desplegado en web** y debe ser navegable por una persona externa al grupo.

Herramientas posibles

Se permiten, entre otras:

- `Streamlit`
- `Dash`
- `Shiny for Python`
- `Next.js`
- `Plotly` , `Leaflet` , `Folium` , `MapLibre` o herramientas equivalentes

No se exige una tecnología específica. Se evalúa la calidad del producto final, no el framework.

Estructura sugerida del proyecto

Una estructura razonable del repositorio podría incluir:

- `data/`
- `notebooks/` o `src/`
- `scripts/`
- `models/`
- `dashboard/`
- `README.md`
- `requirements.txt` o `pyproject.toml`

Entregables

Cada grupo deberá entregar:

1. Repositorio del proyecto

- código limpio y ejecutable;
- instrucciones de instalación;
- documentación clara.

2. Dataset o pipeline de construcción del dataset

- no es necesario subir archivos masivos si hay restricción de tamaño;
- sí es obligatorio explicar cómo se construye.

3. Análisis exploratorio

- visualizaciones;
- hallazgos;
- problemas de calidad de datos.

4. Modelado

- problema definido;
- features;
- modelos comparados;
- métricas;
- análisis de errores.

5. Dashboard web desplegado

- URL accesible;
- navegación clara;
- integración entre datos, análisis y modelo.

6. Presentación final

- síntesis de problema, método, resultados y aprendizajes.

Criterios de evaluación

1. Formulación del problema

- ¿La pregunta es clara?

- ¿La tarea de ML tiene sentido?
- ¿La unidad de análisis está bien definida?

2. Calidad del dataset

- ¿Las fuentes están justificadas?
- ¿El dataset está limpio y documentado?
- ¿Se reconocen sesgos y limitaciones?

3. Modelado y rigor técnico

- ¿Hay una línea base?
- ¿Se comparan modelos con criterio?
- ¿Las métricas corresponden al problema?
- ¿Hay análisis de errores?

4. Dashboard y comunicación

- ¿El dashboard aporta valor real?
- ¿Explica los resultados con claridad?
- ¿Conecta visualmente fuentes, análisis y modelo?

5. Calidad integral del proyecto

- ¿Es reproducible?
- ¿Está bien documentado?
- ¿Muestra criterio y autonomía?

Consejos para un proyecto fuerte

- Es mejor una pregunta pequeña y bien resuelta que un sistema gigantesco y frágil.
- Si una fuente no funciona, documenten el intento y cambien de estrategia.
- No se obsesionen con “capturarlo todo”.
- Elijan una unidad de análisis estable.
- Si usan embeddings, compárenlos con una línea base clásica.
- Eviten targets imposibles de justificar.
- El dashboard debe mostrar también límites y decisiones, no solo éxitos.

Errores frecuentes a evitar

- bajar muchas fuentes sin una pregunta clara;
- construir el dashboard antes del dataset;
- usar modelos sin entender qué predicen;
- confundir visualización con machine learning;
- no documentar limpieza y transformaciones;
- no explicar de dónde salió el target;
- no evaluar errores reales del modelo.

Glosario mínimo

Unidad de análisis

La entidad que representa cada fila principal del dataset. Puede ser un documento, un evento o una ventana temporal.

Target / variable objetivo

La variable que el grupo quiere predecir, clasificar o estimar.

Feature

Variable de entrada usada por el modelo para aprender patrones.

Label

Etiqueta asociada a un ejemplo. En clasificación, normalmente corresponde a la categoría esperada.

EDA

Análisis exploratorio de datos. Sirve para entender distribuciones, relaciones, problemas de calidad y posibles sesgos.

Embedding

Representación numérica densa de texto u objetos, útil para medir similitud o enriquecer modelos.

Pipeline

Secuencia reproducible de pasos para capturar, limpiar, transformar y modelar datos.

Baseline

Modelo o aproximación simple que sirve como punto de comparación.

Validación

Proceso para estimar qué tan bien generaliza un modelo y evitar conclusiones engañosas.

Balanceo de clases

Estrategias para tratar datasets donde unas categorías aparecen mucho más que otras.

Regularización

Mecanismo para controlar la complejidad del modelo y reducir sobreajuste.

Despliegue

Paso en el que el análisis o el modelo se integra en un producto accesible, en este caso un dashboard web.

OSINT

Open-Source Intelligence. Uso de fuentes abiertas para producir información estructurada y útil.

Recomendación metodológica

Una ruta sana para la mayoría de grupos es:

1. escoger una pregunta concreta;
2. validar 2 o 3 fuentes primero;
3. construir una tabla integrada;
4. hacer EDA serio;
5. definir target y features;
6. entrenar y comparar modelos;
7. recién ahí diseñar el dashboard final.

Cierre

Este proyecto no busca que todos lleguen a la misma respuesta. Busca que cada grupo sea capaz de:

- formular un problema propio;
- conseguir datos abiertos útiles;
- construir un dataset defendible;
- aplicar con criterio técnicas de Machine Learning 1 ;
- y traducir todo eso en un producto web que comunique con claridad.

El verdadero reto no es “hacer una página bonita”, sino demostrar que saben pasar de fuentes caóticas a una decisión metodológica sólida.